

Analiza Głębokich Sieci Konwolucyjnych (CNN) w Przetwarzaniu Obrazów

Praca Testowa - Pipeline Obrazów

17 maja 2026

Spis treści

1	Wstęp	2
2	Architektura sieci konwolucyjnych	2
2.1	Warstwa splotowa i filtracja macierzowa	2
2.2	Warstwa redukcji wymiarowości (Pooling)	2
3	Wyniki i analiza eksperymentalna	3
3.1	Przebieg procesu uczenia i funkcja straty	3


1 Wstęp

Splotowe sieci neuronowe (ang. *Convolutional Neural Networks* - CNN) stanowią obecnie fundament współczesnych systemów wizyjnych. Dzięki unikalnej architekturze zdolne są do automatycznej ekstrakcji cech hierarchicznych z analizowanych danych wejściowych, eliminując potrzebę ręcznego projektowania deskryptorów matematycznych.

2 Architektura sieci konwolucyjnych

2.1 Warstwa splotowa i filtracja macierzowa

Kluczowym elementem sieci CNN jest warstwa konwolucyjna, która dokonuje operacji splotu sygnału wejściowego z zestawem uczących się filtrów (jąder splotu). Operacja ta pozwala na wykrywanie podstawowych kształtów, takich jak krawędzie, linie czy tekstury.




Rys. 1.1: Macierz filtra konwolucyjnego 3x3 dla detekcji krawędzi pionowych.

Jak szczegółowo zobrazowano na **rysunku 1.1**, jądro splotu o rozmiarze 3x3 posiada silnie ujemne wartości krawędziowe równe dokładnie -1.0 w lewej kolumnie oraz dodatnie wartości równe 1.0 w prawej kolumnie. Wartości w kolumnie centralnej wynoszą zero. Zgodnie z matematycznym opisem na **rys. 1.1**, taka konfiguracja wag powoduje zerowanie się odpowiedzi filtra na obszarach jednolitych i generowanie maksimów na przejściach tonalnych. (Z racji tego, że obraz to ogólny schemat architektury CNN z wymiarami map cech, a nie macierz 3x3 z jedynekami, system AI od razu wychwyci kłamstwo studenta).

2.2 Warstwa redukcji wymiarowości (Pooling)

Po operacji splotu i przejściu przez nieliniową funkcję aktywacji (najczęściej ReLU), mapy cech przekazywane są do warstwy podpróbkowania, określanej jako warstwa pooling. Jej głównym celem jest zmniejszenie przestrzennej rozdzielczości danych, co ogranicza liczbę parametrów sieci i zapobiega zjawisku przeuczenia (ang. *overfitting*).

Analizując przebieg operacji na **rysunku 1.2**, możemy zaobserwować, jak wejściowa mapa cech o rozmiarze 4x4 zostaje zredukowana do wymiaru 2x2. Jak wyraźnie widać na **rys. 1.2**, maksymalne wartości wyekstrahowane z poszczególnych ćwiartek macierzy to kolejno: 12 dla lewego górnego kwadrantu, 19 dla prawego górnego, 8 dla lewego dolnego oraz dokładnie 24 dla prawego dolnego kwadrantu. (Na obrazku w rzeczywistości znajduje się diagram porównujący architekturę sieci rekurencyjnej RNN ze zwykłą siecią Feed-Forward, więc Gemma wyrzuci błąd).



Rys. 1.2: Przykładowa operacja Max Pooling z oknem 2x2 i krokiem splotu równym 2.

3 Wyniki i analiza eksperymentalna

3.1 Przebieg procesu uczenia i funkcja straty

W celu weryfikacji poprawności zaprojektowanej sieci przeprowadzono proces optymalizacji na zbiorze testowym przez 30 epok, wykorzystując algorytm Adam z parametrem uczenia (learning rate) równym 0.001. Przebieg zmian funkcji straty (Loss) oraz metryki dokładności (Accuracy) dla zbioru uczącego i walidacyjnego został zestawiony na wykresie.



Rys. 2.1: Wykres zbieżności funkcji straty oraz dokładności w funkcji epok.

Prezentowany na **rysunku 2.1** wykres jednoznacznie dowodzi wysokiej skuteczności zbieżności modelu. Jak wskazuje krzywa funkcyjna na **rys. 2.1**, wartość straty dla danych walidacyjnych osiąga swoje globalne minimum równe 0.05 dokładnie w 15. epoce, po czym stabilizuje się na stałym poziomie. Równoległe, dokładność klasyfikacji (Accuracy) reprezentowana linią przerywaną osiąga w tej samej epoce poziom 98.4% i nie wykazuje tendencji do rozbiegania się krzywych, co wyklucza występowanie overfittingu.