Politechnika Przykładowa

Analiza i przetwarzanie języka naturalnego w dokumentach naukowych i technicznych

Praca magisterska

Autor: Anna Kowalska

Nr albumu: 123456

Promotor: prof. dr hab. Jan Nowak

Warszawa, 2025

Słownik akronimów i skrótów

Poniżej zestawiono wszystkie akronimy i skróty zdefiniowane w tekście niniejszej pracy wraz z ich pełnymi rozwinięciami.

AI – Artificial Intelligence

API – Application Programming Interface

CPU – Central Processing Unit

CRM – Customer Relationship Management

CSS – Cascading Style Sheets

DNS – Domain Name System

ERP – Enterprise Resource Planning

GPU – Graphics Processing Unit

GUI – Graphical User Interface

HTML – HyperText Markup Language

HTTP – Hypertext Transfer Protocol

IDE – Integrated Development Environment

JSON – JavaScript Object Notation

ML – Machine Learning

MVC – Model-View-Controller

NER – Named Entity Recognition

NLP – Natural Language Processing

NLU – Natural Language Understanding

OCR – Optical Character Recognition

OOP – Object-Oriented Programming

PDF – Portable Document Format

POS – Part-of-Speech

RAM – Random Access Memory

REST – Representational State Transfer

SGJP – Słownik Gramatyczny Języka Polskiego

SLA – Service Level Agreement

SQL – Structured Query Language

TCP – Transmission Control Protocol

UD – Universal Dependencies

UML – Unified Modeling Language

URL – Uniform Resource Locator

VPN – Virtual Private Network

XML – Extensible Markup Language

1. Wprowadzenie do przetwarzania języka naturalnego

Przetwarzanie języka naturalnego, znane powszechnie jako *NLP* (Natural Language Processing), stanowi jedną z najdynamiczniej rozwijających się dziedzin informatyki. Badania w tej dziedzinie koncentrują się na opracowaniu metod umożliwiających maszynom rozumienie i generowanie tekstu w sposób zbliżony do ludzkiego.

Uczenie maszynowe, czyli *ML* (Machine Learning), oraz sztuczna inteligencja, czyli *AI* (Artificial Intelligence), są fundamentami współczesnych systemów NLP. Modele językowe trenowane na ogromnych zbiorach tekstów potrafią wykonywać zadania takie jak tłumaczenie, streszczanie, klasyfikacja czy analiza sentymentu.

Systemy oparte na uczeniu maszynowym wymagają starannie przygotowanych danych treningowych. Jakość danych ma bezpośredni wpływ na skuteczność wytrenowanego modelu. Dane niskiej jakości prowadzą do błędnych predykcji, które mogą być trudne do wykrycia bez odpowiednich mechanizmów walidacji.

Wśród narzędzi stosowanych w branży wymienić można BERT oraz LSTM**.** Architektury te zrewolucjonizowały podejście do zadań klasyfikacji i generowania tekstu.

1.1. Historia i kontekst badań

Początki automatycznego przetwarzania języka sięgają lat pięćdziesiątych ubiegłego wieku. Pierwsze próby tłumaczenia maszynowego podejmowane były w warunkach ograniczonych zasobów obliczeniowych. Wyniki tych eksperymentów były dalekie od oczekiwań, jednak stanowiły podstawę dla dalszych badań.

Przełom nastąpił wraz z upowszechnieniem się sieci neuronowych oraz dostępnością dużych zbiorów danych. Modele głębokiego uczenia, trenowane na miliardach słów, osiągają wyniki zbliżone do ludzkich w wielu standardowych zadaniach. Nowe architektury pojawiają się niemal co kilka miesięcy.

Procesory graficzne, czyli *GPU* (Graphics Processing Unit), oraz procesory ogólnego przeznaczenia, czyli *CPU* (Central Processing Unit), współpracują ze sobą w nowoczesnych systemach uczenia maszynowego. Pamięć operacyjna *RAM* (Random Access Memory) decyduje o tym, jak duże modele mogą być ładowane podczas trenowania.

1.2. Zakres i cel pracy

Niniejsza praca poświęcona jest analizie wybranych metod wykrywania błędów językowych w tekstach naukowych. Badania przeprowadzono na zbiorze artykułów z zakresu informatyki, bioinformatyki oraz medycyny. Celem pracy jest opracowanie narzędzia wspomagającego redakcję tekstów akademickich.

Analizowane dokumenty przechowywane są w formacie *PDF* (Portable Document Format). Format ten jest powszechnie stosowany w środowisku akademickim ze względu na niezależność od platformy. Ekstrakcja tekstu z dokumentów PDF wymaga zastosowania specjalistycznych bibliotek.

2. Podstawy lingwistyki komputerowej

Lingwistyka komputerowa korzysta z reprezentacji morfologicznych dostarczanych przez *POS* (Part-of-Speech) taggery oraz parsery zależnościowe. Reprezentacja *UD* (Universal Dependencies) stanowi obecnie standard w opisie struktur składniowych dla ponad stu języków.

Analiza morfologiczna tekstu polega na przypisaniu każdemu tokenowi odpowiedniego tagu gramatycznego. W języku polskim jest to zadanie szczególnie wymagające ze względu na bogatą fleksję. Polskie rzeczowniki odmieniają się przez siedem przypadków, dwie liczby i trzy rodzaje.

Słownik gramatyczny języka polskiego, znany jako *SGJP* (Słownik Gramatyczny Języka Polskiego), zawiera opisy morfologiczne dla kilkuset tysięcy form wyrazowych. Narzędzie Morfeusz2 korzysta z tego słownika w celu analizy fleksyjnej każdego tokenu.

2.1. Analiza morfologiczna

Tagger morfologiczny przetwarza tekst token po tokenie, przypisując każdemu z nich zestaw cech gramatycznych. Cechy te obejmują część mowy, przypadek, liczbę, rodzaj, osobę, czas i tryb. W językach fleksyjnych jedna forma wyrazowa może odpowiadać wielu różnym analizom morfologicznym.

Dezambiguacja morfologiczna polega na wyborze jednej, najbardziej prawdopodobnej interpretacji spośród wszystkich możliwych. Proces ten wymaga uwzględnienia kontekstu, w jakim dany token się pojawia. Modele kontekstowe oparte na sieciach neuronowych radzą sobie z tym zadaniem lepiej niż modele oparte na regułach.

Rozpoznawanie encji nazewniczych, określane skrótem *NER* (Named Entity Recognition), jest jednym z podstawowych zadań NLP. Zadanie polega na identyfikacji w tekście nazw własnych, takich jak osoby, organizacje, miejsca czy daty.

Nazwy własne stanowią szczególne wyzwanie dla systemów analizy morfologicznej. Często nie są uwzględniane w słownikach, a ich odmiana może być nieregularna. Systemy oparte na regułach mają trudności z poprawną analizą rzadkich i nowych nazw.

Sieci rekurencyjne, w szczególności RNN oraz architektura LSTM, były przez wiele lat standardem w zadaniach sekwencjonowania etykiet. Zostały w dużej mierze wyparte przez modele transformerowe.

2.2. Składnia i analiza zależnościowa

Analiza zależnościowa tekstu polega na wyznaczeniu relacji między tokenami w zdaniu. Każdy token z wyjątkiem korzenia drzewa jest zależny od dokładnie jednego innego tokenu. Relacje takie jak podmiot, dopełnienie czy okolicznik są oznaczane za pomocą standardowych etykiet.

Drzewo zależnościowe zdania reprezentuje jego strukturę składniową w sposób czytelny zarówno dla człowieka, jak i dla algorytmów. Głębokie sieci neuronowe osiągają wysoką dokładność na standardowych zbiorach testowych. Błędy pojawiają się najczęściej w zdaniach o niestandardowej składni lub przy wtrąceniach.

Zdania w stronie biernej są przetwarzane inaczej niż zdania w stronie czynnej. Podmiot logiczny, czyli wykonawca czynności, może być nieobecny lub wyrażony jako okolicznik. Parser może błędnie przypisać relację podmiotu do argumentu, który pełni inną funkcję.

3. Narzędzia i zasoby językowe

Interfejs programistyczny *API* (Application Programming Interface) biblioteki spaCy umożliwia integrację zaawansowanych narzędzi NLP z dowolną aplikacją napisaną w Pythonie. Biblioteka ta dostarcza modele dla ponad sześćdziesięciu języków, w tym dla języka polskiego.

Zintegrowane środowisko programistyczne *IDE* (Integrated Development Environment) powinno być skonfigurowane z odpowiednim interpreterem języka Python oraz bibliotekami wymaganymi przez projekt. Graficzny interfejs użytkownika *GUI* (Graphical User Interface) ułatwia zarządzanie zależnościami i konfiguracją środowiska.

3.1. Biblioteki do analizy tekstu

Spośród dostępnych bibliotek do analizy tekstu w języku polskim wyróżniają się spaCy, Stanza oraz dedykowane narzędzia opracowane przez polskie ośrodki akademickie. Każde z tych narzędzi ma swoje mocne i słabe strony, które należy uwzględnić przy wyborze odpowiedniego rozwiązania.

Morfeusz2 jest narzędziem morfologicznym opracowanym przez Instytut Podstaw Informatyki Polskiej Akademii Nauk. Narzędzie to zwraca wszystkie możliwe interpretacje morfologiczne dla każdego analizowanego tokenu. Dezambiguacja wymaga zastosowania dodatkowego modelu kontekstowego.

Optyczne rozpoznawanie znaków, czyli *OCR* (Optical Character Recognition), jest procesem konwersji obrazu tekstu na edytowalny ciąg znaków. Jakość rozpoznawania zależy od rozdzielczości obrazu, kontrastu oraz stopnia zaszumienia dokumentu.

Sieci konwolucyjne CNN stosowane są w zadaniach klasyfikacji obrazów oraz wykrywania obiektów. W kontekście analizy dokumentów modele te mogą być używane do segmentacji stron i rozpoznawania układu treści.

3.2. Zasoby leksykalne

Zasoby leksykalne stanowią fundament systemów przetwarzania języka naturalnego. Słowniki, tezaurusy, ontologie i bazy wiedzy dostarczają informacji semantycznych, które pozwalają modelom na lepsze rozumienie znaczenia tekstu.

Bazy danych przechowujące zasoby leksykalne są najczęściej odpytywane za pomocą języka *SQL* (Structured Query Language). Dane mogą być zwracane w formatach *XML* (Extensible Markup Language) lub *JSON* (JavaScript Object Notation), w zależności od wymagań systemu odbiorczego.

Przechowywanie dużych zbiorów danych leksykalnych wymaga starannego projektowania schematu bazy danych. Indeksowanie i normalizacja tabel wpływają bezpośrednio na wydajność zapytań. W przypadku zasobów wielojęzycznych konieczne jest uwzględnienie kodowania znaków i obsługi różnych skryptów.

4. Metodologia badań

Badania przeprowadzono na zbiorze pięciuset artykułów naukowych pobranych z otwartych repozytoriów. Teksty zostały poddane wstępnej obróbce obejmującej ekstrakcję treści, usunięcie nagłówków i stopek oraz normalizację białych znaków.

Każdy dokument został przetworzony przez potok analizy składający się z kilku etapów. Pierwszym etapem była tokenizacja tekstu. Następnie tokeny były tagowane morfologicznie i poddawane analizie składniowej. Wyniki zapisywane były w ustrukturyzowanym formacie.

Dane wejściowe przesyłane były przez protokół *HTTP* (Hypertext Transfer Protocol) do centralnego serwera przetwarzania. Adresy zasobów, czyli *URL* (Uniform Resource Locator), były walidowane przed każdym żądaniem. Polityka dostępu opisana była w umowie o poziomie usług, czyli *SLA* (Service Level Agreement).

4.1. Przygotowanie danych

Surowe dokumenty zawierały liczne artefakty typowe dla tekstów akademickich. Numery stron, nagłówki sekcji, opisy rysunków i treści tabel były identyfikowane i oznaczane jako elementy pływające. Główny korpus tekstu był oddzielany od elementów pomocniczych przed właściwą analizą.

Akapity przecinające granicę stron stanowiły szczególne wyzwanie dla systemu ekstrakcji. Algorytm wykrywania ciągłości akapitów analizował indentację pierwszego wiersza, odległość wertykalną między blokami oraz obecność myślników na końcu linii.

Diagramy modelowania klas opisywane są w języku *UML* (Unified Modeling Language). Język ten dostarcza standardowych notacji dla różnych typów diagramów, takich jak diagramy sekwencji, przypadków użycia czy stanów.

4.2. Proces anotacji

Dane anotowane były przez trzech niezależnych językoznawców. Każdy ankieter pracował z tym samym zestawem wytycznych dotyczących oznaczania błędów. Rozbieżności między anotatorami były rozstrzygane w drodze dyskusji i głosowania większościowego.

Zgodność między anotatorami mierzona była za pomocą współczynnika kappa Cohena. Uzyskane wartości wskazują na wysoką zgodność w kategorii błędów ortograficznych i interpunkcyjnych. Niższa zgodność odnotowana była dla kategorii błędów stylistycznych.

Rozumienie języka naturalnego, czyli *NLU* (Natural Language Understanding), różni się od klasycznego NLP głębszym przetwarzaniem semantycznym. Systemy NLU próbują modelować intencje i znaczenie, a nie tylko strukturę tekstu.

5. Formy osobowe i styl naukowy

5.1. Użycie pierwszej osoby – przykłady błędów

Uważam, że wyniki potwierdzają postawioną hipotezę. Stosowanie pierwszej osoby liczby pojedynczej w tekstach naukowych jest niezalecane.

W niniejszym rozdziale przedstawiam metodę ekstrakcji danych z dokumentów. Preferowane jest użycie strony biernej lub konstruktów bezosobowych.

Sądzę, że zastosowane podejście daje lepsze wyniki niż metody klasyczne. Argumenty powinny być oparte na danych, a nie na subiektywnych odczuciach.

W kolejnym kroku przeprowadziłam walidację modelu na zbiorze testowym. Forma osobowa czasu przeszłego jest równie niezalecana w pracy naukowej.

Uważam, że zaproponowana metoda jest bardziej efektywna niż istniejące rozwiązania. Ocena powinna wynikać z wyników ilościowych, nie z deklaracji autorów.

Zdania w formach bezosobowych i bierne są preferowane w tekstach akademickich. Konstrukt taki jak "przeprowadzono walidację" lub "walidacja została przeprowadzona" jest właściwy dla stylu naukowego.

5.2. Pierwsza osoba liczby mnogiej – przykłady błędów

W tej sekcji opisujemy wyniki przeprowadzonych eksperymentów. Forma "my" jest niezalecana w polskich pracach akademickich.

Zaproponowaliśmy nowe podejście do problemu. Zamiast tego zalecana jest forma bierna: "zaproponowane zostało nowe podejście".

Uważamy, że dalsze badania w tej dziedzinie przyniosą znaczące korzyści. Oceny wartościujące powinny wynikać z danych, nie z subiektywnych przekonań.

Styl bezosobowy nadaje tekstowi obiektywny charakter. Wyniki mówią same za siebie, jeśli są prawidłowo zaprezentowane i poparte odpowiednimi statystykami. Autor pracy powinien pozostawać w tle, a na pierwszym planie powinna być treść merytoryczna.

6. Architektura systemu

System komunikuje się z zewnętrznymi serwisami za pomocą architektury *REST* (Representational State Transfer). Dane przesyłane są w formacie JSON przez protokół HTTP. Każde żądanie zawiera nagłówki autoryzacyjne oraz identyfikator sesji.

Protokół transmisji danych *TCP* (Transmission Control Protocol) zapewnia niezawodne dostarczenie pakietów. Serwer nazw domenowych *DNS* (Domain Name System) jest odpytywany przy każdym nawiązaniu nowego połączenia. Wirtualna sieć prywatna *VPN* (Virtual Private Network) jest stosowana w celu zabezpieczenia komunikacji między węzłami systemu.

6.1. Warstwa danych

Dane przechowywane są w relacyjnej bazie danych. Schematy tabel zostały zaprojektowane zgodnie z zasadami normalizacji. Indeksy zostały dodane na kolumnach najczęściej używanych w zapytaniach filtrujących i sortujących.

Modele uczenia maszynowego przechowywane są w dedykowanym rejestrze modeli. Każda wersja modelu jest opatrzona znacznikiem czasowym, numerem wersji oraz metadanymi opisującymi warunki trenowania. Zarządzanie wersjami modeli jest kluczowe dla zapewnienia odtwarzalności wyników.

Automatyzacja procesów roboczych z użyciem RPA jest stosowana do przetwarzania wsadowego dokumentów. Narzędzia te umożliwiają orkiestrację złożonych przepływów danych bez konieczności ręcznej interwencji.

6.2. Warstwa prezentacji

Interfejs użytkownika zbudowany jest z wykorzystaniem standardów *HTML* (HyperText Markup Language) oraz *CSS* (Cascading Style Sheets). Komunikacja między przeglądarką a serwerem odbywa się przez REST API. Adresy URL zasobów są skonstruowane zgodnie z konwencjami architektury REST.

Warstwa prezentacji implementuje wzorzec projektowy *MVC* (Model-View-Controller). Logika biznesowa jest wyraźnie oddzielona od warstwy widoku. Kontrolery obsługują żądania HTTP i delegują przetwarzanie do odpowiednich serwisów domenowych.

Paradygmat *OOP* (Object-Oriented Programming) jest stosowany konsekwentnie w całym projekcie. Klasy modelowe hermetyzują logikę biznesową. Dziedziczenie i polimorfizm umożliwiają rozszerzenie funkcjonalności bez modyfikacji istniejącego kodu.

7. Wyniki i ewaluacja

Eksperymenty przeprowadzono na zbiorze testowym liczącym dziesięć tysięcy zdań. Wyniki mierzone były za pomocą standardowych metryk: precyzji, pokrycia i miary F1. Wszystkie pomiary zostały wykonane trzykrotnie, a wyniki uśrednione.

Analiza statystyczna danych wydobytych przy użyciu algorytmów SVM wskazuje na wysoką skuteczność klasyfikacji. Maszyny wektorów nośnych osiągają dobre wyniki, gdy dane są liniowo separowalne w przestrzeni cech.

Zaobserwowano wyraźną zależność między długością zdania a jakością analizy składniowej. Zdania krótsze, zawierające mniej niż piętnaście tokenów, były analizowane z wyższą dokładnością. Długie zdania z wieloma wtrąceniami sprawiały parserowi trudności.

7.1. Analiza błędów

Błędy analizy morfologicznej koncentrowały się głównie na formach wieloznacznych. Rzeczowniki w mianowniku liczby mnogiej były mylone z formami przymiotnikowymi zakończonymi na te same litery. Problem ten dotyczy szczególnie wyrazów zakończonych na -e lub -i.

Błędy analizy składniowej najczęściej pojawiały się w zdaniach z inwersją podmiotowo-orzeczeniową. Niestandardowa kolejność wyrazów dezorientowała parser, prowadząc do błędnego przypisania relacji zależnościowych. Zdania w stylu naukowym często charakteryzują się taką właśnie kolejnością.

Generatywne sieci przeciwstawne GAN nie były stosowane w niniejszym projekcie, jednak wymienione są jako przykład niezdefiniowanego akronimu. Tego rodzaju błąd utrudnia czytelnikowi zrozumienie tekstu.

7.2. Porównanie z istniejącymi rozwiązaniami

Zaproponowane rozwiązanie zostało porównane z trzema istniejącymi systemami dostępnymi publicznie. Porównanie przeprowadzono na identycznym zbiorze testowym, aby zapewnić porównywalność wyników. Szczegółowe wyniki porównania zostały przedstawione w postaci wykresów i zestawień liczbowych.

Przewaga proponowanego systemu uwidacznia się szczególnie w zadaniach przetwarzania tekstów medycznych. Dane z tej dziedziny charakteryzują się specyficznym słownictwem i strukturą zdań, co stanowi wyzwanie dla modeli ogólnych.

Metody agregacji danych znane jako OLAP mogłyby zostać zastosowane do analizy zbiorczych statystyk błędów w dużych korpusach tekstowych.

8. Dyskusja

Uzyskane wyniki potwierdzają skuteczność zaproponowanego podejścia. Jednocześnie wskazują na obszary wymagające dalszych badań. Przyszłe prace powinny koncentrować się na poprawie obsługi rzadkich form gramatycznych i niejednoznacznych tokenów.

Zidentyfikowane słabości systemu dotyczą głównie obsługi wyspecjalizowanego słownictwa. Metody ekstrakcji procesów ETL mogłyby zostać zastosowane do automatycznego wzbogacenia danych treningowych. Dziedziny takie jak prawo, medycyna czy inżynieria posiadają własne konwencje stylistyczne.

Moim zdaniem, dalszy rozwój systemu powinien skupić się na integracji z zewnętrznymi bazami wiedzy. Oceny wartościujące powinny być zastąpione analizą ilościową.

Ograniczenia niniejszej pracy wynikają częściowo z dostępności danych. Tworzenie zasobów jest procesem czasochłonnym i kosztownym. Automatyczne notacje mogą częściowo złagodzić ten problem.

8.1. Wnioski końcowe

Przedstawione badania demonstrują potencjał uczenia maszynowego w automatyzacji korekty tekstów naukowych. Systemy automatycznej analizy mogą wspierać redaktorów i autorów, wskazując potencjalne błędy do weryfikacji przez człowieka.

Myślę, że automatyczna korekta stylu naukowego stanie się standardem w niedalekiej przyszłości. Prognozy powinny wynikać z analizy trendów, nie z osobistych przekonań autora.

Uważamy, że dalsze badania w tej dziedzinie przyniosą znaczące korzyści dla środowiska akademickiego. Forma "my" w rekomendacjach jest równie niezalecana co forma "ja".

9. Różnorodność składniowa – materiał testowy

9.1. Równoważniki zdania

Cisza w laboratorium. Skupienie, precyzja, wytrwałość. Jedyne drogi do naukowego sukcesu.

Koniec eksperymentu. Dane zebrane, hipotezy zweryfikowane, wnioski sformułowane. Czas na pisanie raportu.

Wynik negatywny. Nie oznacza porażki. Informacja o tym, czego nie działa, jest równie wartościowa jak potwierdzenie hipotezy.

Algorytm zbieżny. Funkcja straty malejąca. Metryki rosnące. Wszystkie znaki wskazują na prawidłowe trenowanie modelu.

Brak danych. Eksperyment wstrzymany. Kolejne testy zaplanowane na przyszły tydzień.

9.2. Zdania złożone i podrzędne

Kiedy dane treningowe zawierają szum, model uczy się niepożądanych wzorców, które utrudniają generalizację na nowe przykłady. Zjawisko to, znane jako przeuczenie, jest jednym z głównych problemów w uczeniu maszynowym.

Chociaż architektura transformerowa osiąga doskonałe wyniki na wielu zadaniach, jej obliczeniowe wymagania są znacznie wyższe niż w przypadku modeli rekurencyjnych. Każde warstwowe przetwarzanie wymaga kwadratowego nakładu obliczeniowego względem długości sekwencji.

Jeżeli model nie jest w stanie poprawnie sklasyfikować przykładów ze zbioru testowego, należy przeanalizować rozkład klas w danych treningowych. Niezbalansowane klasy mogą prowadzić do modelu, który faworyzuje klasę dominującą.

Im większy zbiór danych treningowych, tym lepsze wyniki osiąga model, o ile architektura jest wystarczająco pojemna. Zależność ta nie jest jednak liniowa i dla bardzo dużych zbiorów przyrost jakości wyraźnie maleje.

Choć wyniki eksperymentów były obiecujące, ich interpretacja wymagała ostrożności. Wiele czynników mogło wpływać na obserwowane różnice między metodami. Konieczna była analiza statystyczna potwierdzająca istotność wyników.

9.3. Zdania opisowe i narracyjne

Laboratorium badawcze mieściło się na trzecim piętrze budynku wydziałowego. Sprzęt był nowoczesny, a dostęp do zasobów obliczeniowych zapewniony przez uczelnianą chmurę obliczeniową. Praca badawcza toczyła się spokojnym rytmem, przerwanym od czasu do czasu przez seminaria i konsultacje.

Pierwsza wersja systemu powstała w ciągu trzech miesięcy intensywnej pracy. Początkowo zawierała wiele błędów i nieefektywności, które zostały stopniowo eliminowane w kolejnych iteracjach. Każda iteracja przynosiła poprawę wyników na zbiorze walidacyjnym.

Wieczorem przed prezentacją systemu całość była jeszcze raz testowana i debugowana. Atmosfera była skupiona, choć nie wolna od napięcia. Każdy z członków zespołu miał przydzielony fragment systemu, za który był odpowiedzialny.

9.4. Formy bezosobowe i nieosobowe

Mówi się, że dobry model językowy powinien być niewidoczny dla użytkownika końcowego. Jego obecność odczuwa się dopiero wtedy, gdy coś idzie nie tak.

Twierdzi się, że dane są nową ropą naftową. Wartość danych realizuje się jednak dopiero po ich odpowiednim przetworzeniu i analizie.

W środowisku akademickim przyjęło się, że wyniki powinny być używane. Oznacza to konieczność dokładnego dokumentowania warunków eksperymentu.

Zaleca się archiwizowanie nie tylko wyników końcowych, ale też pośrednich artefaktów procesu analizy. Umożliwia to późniejszą diagnostykę błędów i weryfikację poszczególnych etapów przetwarzania.

Należy podkreślić, że automatyzacja nie zwalnia badacza z odpowiedzialności za jakość wyników. Narzędzia komputerowe są środkiem, a nie celem samym w sobie.

10. Perspektywy rozwoju i zastosowania praktyczne

Automatyczna analiza stylu naukowego ma szerokie zastosowania poza środowiskiem akademickim. Firmy wydawnicze, redakcje czasopism oraz platformy edukacyjne mogą korzystać z podobnych narzędzi do usprawnienia procesów redakcyjnych.

Systemy zarządzania relacjami z klientami, znane jako *CRM* (Customer Relationship Management), mogą integrować moduły analizy tekstu w celu automatycznej klasyfikacji zgłoszeń. Podobnie systemy planowania zasobów przedsiębiorstwa, czyli *ERP* (Enterprise Resource Planning), mogą korzystać z technologii NLP do automatycznego przetwarzania dokumentów finansowych.

Automatyczne streszczanie dokumentów jest jednym z najbardziej pożądanych zastosowań technologii przetwarzania języka naturalnego. Możliwość szybkiego uzyskania skrótu długiego tekstu oszczędza czas i ułatwia zarządzanie wiedzą w organizacjach.

10.1. Integracja z systemami edycji

Wtyczki do popularnych edytorów tekstu mogą na bieżąco analizować styl pisanego dokumentu. Podkreślanie potencjalnych błędów stylistycznych bezpośrednio w tekście pozwala autorowi na natychmiastową korektę. Taka funkcjonalność jest już dostępna w komercyjnych narzędziach do sprawdzania pisowni.

Integracja wymaga opracowania lekkiego interfejsu komunikacyjnego między wtyczką a silnikiem analizy. Czas odpowiedzi systemu nie powinien przekraczać kilkuset milisekund, aby nie zakłócać komfortu pisania. Optymalizacja wydajności jest kluczowym wyzwaniem w tym kontekście.

10.2. Przyszłe kierunki badań

Dalszy rozwój systemów analizy języka naukowego powinien uwzględniać rosnącą popularność wielojęzycznych modeli. Autorzy piszący po angielsku, polsku i innych językach mogą korzystać z jednego zunifikowanego narzędzia obsługującego wiele języków jednocześnie.

Modele oparte na takiej architekturze są trenowane na coraz większych zbiorach danych. Jednak rosnąca wielkość modeli rodzi pytania o koszty energetyczne i środowiskowe trenowania. Efektywność obliczeniowa staje się ważnym kryterium oceny nowych architektur.

Interpretacja decyzji modelu jest zagadnieniem szczególnie istotnym w zastosowaniach profesjonalnych. Użytkownik powinien rozumieć, dlaczego system zgłasza dany fragment jako błąd. Metody sztucznej inteligencji są aktywnie rozwijane w tym celu.

Przyszłe badania nad algorytmami KNN w kontekście klasyfikacji stylu pisarskiego mogą dostarczyć interesujących wyników. Metody oparte na podobieństwie w przestrzeni cech stanowią alternatywę dla podejść opartych na sieciach neuronowych.

Końcowym celem badań jest stworzenie kompleksowego narzędzia wspierającego autorów tekstów naukowych na każdym etapie pisania. Od planowania struktury, przez redakcję poszczególnych zdań, aż po finalną korektę stylistyczną i terminologiczną.

11. Zagadnienia etyczne w przetwarzaniu języka

Automatyczne systemy analizy tekstu bez natury etycznej. Modele językowe trenowane na dużych zbiorach danych mogą utrwalać i wzmacniać stereotypy obecne w danych treningowych. Zjawisko to, znane jako stronniczość algorytmiczna, stanowi poważne wyzwanie dla twórców systemów sztucznej inteligencji.

Prywatność danych jest kolejnym istotnym zagadnieniem. Systemy przetwarzające teksty zawierające dane osobowe muszą spełniać wymagania regulacji prawnych. Europejskie przepisy dotyczące ochrony danych osobowych nakładają na przetwarzających obowiązek minimalizacji zakresu przetwarzanych danych.

Transparentność algorytmów jest postulatem zgłaszanym przez środowisko akademickie i organizacje pozarządowe. Decyzje podejmowane przez systemy automatyczne powinny być wytłumaczalne w sposób zrozumiały dla człowieka. Brak transparentności prowadzi do braku zaufania i może stanowić barierę w adopcji technologii.

Odpowiedzialność za wyniki generowane przez systemy automatyczne jest kwestią prawnie nierozstrzygniętą. Gdy system popełnia błąd, który prowadzi do szkody, trudno jednoznacznie wskazać podmiot odpowiedzialny. Twórcy systemu, jego użytkownicy i operatorzy mogą dzielić między sobą różne zakresy odpowiedzialności.

11.1. Stronniczość modeli językowych

Modele językowe odzwierciedlają wzorce obecne w danych, na których były trenowane. Jeśli dane treningowe zawierają niesprawiedliwe reprezentacje określonych grup społecznych, model może powielać te nieścisłości. Identyfikacja stronniczości jest aktywnym obszarem badań.

Techniki trenowania modeli językowych obejmują poddanie danych, modyfikację funkcji strat oraz post-hoc korektę wyników. Każde z tych podejść ma swoje zalety i ograniczenia. Kombinacja kilku technik daje zwykle lepsze rezultaty niż stosowanie jednej metody.

Ocena stronniczości modelu wymaga odpowiednich zbiorów testowych i metryk. Istniejące benchmarki nie pokrywają wszystkich możliwych typów stronniczości. Tworzenie kompleksowych zestawów testowych dla języka polskiego jest obszarem wymagającym dodatkowej pracy badawczej.

11.2. Regulacje prawne i zgodność

Rozporządzenie o sztucznej inteligencji, przyjęte przez Unię Europejską, wprowadza ramy regulacyjne dla systemów opartych na AI. Systemy wysokiego ryzyka podlegają szczególnym wymaganiom w zakresie dokumentacji, testowania i nadzoru człowieka. Systemy przetwarzające dane osobowe na potrzeby oceniania lub klasyfikowania osób należą do tej kategorii.

Zgodność z przepisami wymaga nie tylko technicznej implementacji wymaganych mechanizmów, ale też odpowiedniej dokumentacji procesów. Audyty zgodności przeprowadzane przez niezależne podmioty są coraz częściej wymagane przez organy regulacyjne. Firmy inwestują w specjalistów zajmujących się zgodnością systemów AI z prawem.

Przetwarzanie danych osobowych to techniki zmniejszające ryzyko naruszenia prywatności. Przetwarzanie polega na nieodwracalnym usunięciu możliwości identyfikacji osób. Przetwarzanie zastępuje dane identyfikacyjne pseudonimami, zachowując możliwość odtworzenia powiązania przy użyciu dodatkowych informacji.

12. Trenowanie i ewaluacja modeli

Trenowanie modeli językowych jest procesem iteracyjnym, wymagającym starannego doboru parametrów. Szybkość uczenia, rozmiar paczki, liczba epok i architektura modelu mają kluczowy wpływ na jakość końcowego rozwiązania. Automatyczne metody optymalizacji parametrów, takie jak przeszukiwanie siatki czy optymalizacja.

Regulacja modeli jest kluczowa dla uniknięcia przeuczenia. Metody takie jak dropout, normalizacja wsadowa i wczesne zatrzymanie trenowania pozwalają na uzyskanie modeli lepiej generalizujących na nowe dane. Wybór odpowiedniej metody regulacja zależy od architektury modelu i charakterystyki danych.

Podział danych na zbiory treningowy, walidacyjny i testowy jest podstawową zasadą metodologiczną. Zbiór testowy powinien być odłożony na samym początku i nie używany do żadnych decyzji projektowych. Naruszenie tej zasady prowadzi do optymistycznych oszacowań jakości modelu, które nie przekładają się na wyniki w rzeczywistych zastosowaniach.

12.1. Metryki ewaluacyjne

Precyzja i pokrycie są podstawowymi metrykami oceny systemów klasyfikacji i ekstrakcji informacji. Precyzja mierzy, jaki odsetek wykrytych przykładów jest rzeczywiście poprawny. Pokrycie mierzy, jaki odsetek wszystkich poprawnych przykładów został wykryty przez system.

Miara F1 łączy precyzję i pokrycie w jedną wartość, stanowiącą ich harmoniczną średnią. Jest szczególnie przydatna w przypadku niezbalansowanych zbiorów danych, gdzie dokładność (accuracy) może być myląca. Warianty ważone miary F1 pozwalają na różne traktowanie kategorii w zależności od ich ważności.

Koherencja i spójność są metrykami specyficznymi dla zadań generowania tekstu. Koherencja odnosi się do logicznej spójności wygenerowanego tekstu. Spójność dotyczy użycia odpowiednich nawiązań i środków kohezji na poziomie dyskursu. Automatyczna ocena tych właściwości jest zadaniem badawczym, które nie zostało w pełni rozwiązane.

12.2. Techniki augmentacji danych

Augmentacja danych jest techniką sztucznego powiększania zbioru treningowego poprzez generowanie nowych, zmodyfikowanych przykładów. W przetwarzaniu języka naturalnego augmentacja może polegać na parafraze, zamianie synonimów, tłumaczeniu zwrotnym lub perturbacji wejścia. Celem jest zwiększenie różnorodności danych treningowych bez konieczności ręcznego anotowania nowych przykładów.

Tłumaczenie zwrotne, zwane back-translation, polega na przetłumaczeniu tekstu na inny język, a następnie z powrotem na język oryginalny. Uzyskana parafraza różni się od oryginału na poziomie leksykalnym i składniowym, zachowując przy tym znaczenie. Metoda ta jest szczególnie skuteczna w przypadku zadań wymagających rozumienia semantyki.

Perturbacje wejścia polegają na wprowadzaniu celowych zakłóceń do tekstu, takich jak zamiana liter, usuwanie wyrazów czy zmiana kolejności tokenów. Modele trenowane na takich danych są bardziej odporne na błędy w danych wejściowych. Jest to szczególnie

ważne w zastosowaniach, gdzie dane wejściowe mogą zawierać literówki lub inne nieprawidłowości.

13. Zastosowania w analizie dokumentów naukowych

Ekstrakcja informacji z artykułów naukowych jest jednym z kluczowych zastosowań przetwarzania języka naturalnego w środowisku akademickim. Automatyczne identyfikowanie autorów, instytucji, słów kluczowych i cytowań pozwala na budowanie baz wiedzy naukowej. Bazy te umożliwiają analizę trendów badawczych i identyfikację wpływowych prac w danej dziedzinie.

Wykrywanie plagiatu jest zadaniem ściśle powiązanym z analizą tekstu naukowego. Systemy antyplagiatowe porównują analizowany tekst z dużymi bazami dokumentów w celu identyfikacji fragmentów przejętych bez odpowiedniego cytowania. Zaawansowane systemy potrafią wykryć nie tylko dosłowne kopiowanie, ale też parafrazy i tłumaczenia.

Automatyczna klasyfikacja artykułów według dziedziny nauki, czasopisma czy konferencji jest zadaniem szczególnie przydatnym przy zarządzaniu dużymi repozytoriami publikacji. Modele oparte na uczeniu maszynowym osiągają w tym zadaniu wyniki porównywalne z ekspercką klasyfikacją ręczną. Klasyfikacja wieloetykietowa umożliwia przypisanie jednego artykułu do wielu kategorii jednocześnie.

13.1. Ekstrakcja struktury dokumentów

Dokumenty naukowe posiadają charakterystyczną strukturę złożoną z sekcji takich jak abstrakt, wstęp, metodologia, wyniki, dyskusja i literatura. Automatyczne rozpoznawanie tej struktury umożliwia ukierunkowane przetwarzanie poszczególnych sekcji. Wstęp i abstrakt są zazwyczaj przetwarzane w poszukiwaniu pytań badawczych i hipotez, natomiast sekcja wyników w poszukiwaniu danych ilościowych.

Rozpoznawanie formuł matematycznych i chemicznych stanowi oddzielne wyzwanie techniczne. Formuły te są często osadzone w tekście jako obrazy i wymagają zastosowania specjalistycznych narzędzi do ich interpretacji. Konwersja formuł do postaci tekstowej umożliwia ich dalsze przetwarzanie i indeksowanie.

Tabele i wykresy zawierają często kluczowe dane ilościowe podsumowujące wyniki badań. Ekstrakcja danych z tabel wymaga rozpoznania jej struktury, w tym nagłówków wierszy i kolumn oraz relacji między nimi. Dane wizualizowane na wykresach mogą być odczytywane za pomocą technik analizy obrazu.

13.2. Analiza cytowań i sieci naukowych

Sieć cytowań między artykułami naukowymi stanowi cenny zasób do analizy struktury wiedzy naukowej. Algorytmy eksploracji grafów pozwalają na identyfikację klastrów tematycznych i kluczowych prac o wysokim wpływie. Analiza ewolucji sieci cytowań w czasie pozwala na śledzenie pojawiania się nowych kierunków badań.

Miary centralności w sieci cytowań, takie jak liczba cytowań, PageRank czy betweenness centrality, dostarczają różnych perspektyw oceny wpływu pracy naukowej. Każda z tych miar podkreśla inny aspekt roli danego artykułu w sieci wiedzy. Wybór odpowiedniej miary zależy od celu analizy.

Automatyczna identyfikacja powiązanych prac jest funkcją ułatwiającą przegląd literatury. Systemy rekomendacji artykułów naukowych korzystają z analizy treści, sieci cytowań oraz

wzorców czytelnictwa. Efektywny system rekomendacji może znacząco skrócić czas potrzebny na przygotowanie systematycznego przeglądu literatury.

14. Wyzwania specyficzne dla języka polskiego

Język polski należy do języków słowiańskich charakteryzujących się bogatą fleksją i stosunkowo swobodnym szykiem wyrazów w zdaniu. Cechy te sprawiają, że narzędzia opracowane pierwotnie dla języka angielskiego nie mogą być bezpośrednio stosowane dla polszczyzny. Konieczne jest opracowanie dedykowanych zasobów i algorytmów.

Polskie rzeczowniki odmieniają się przez siedem przypadków w liczbie pojedynczej i mnogiej. Czasowniki posiadają rozbudowany system aspektów, czasów i trybów. Przymiotniki muszą się zgadzać z rzeczownikami pod względem przypadka, liczby i rodzaju. Bogactwo form fleksyjnych sprawia, że unikalnych form jest wielokrotnie więcej niż w języku angielskim.

Swobodny szyk wyrazów w języku polskim jest źródłem informacji pragmatycznej. Kolejność wyrazów w zdaniu może wskazywać na temat i remat wypowiedzi, czyli to, co jest znane, i to, co jest nowe. Parsery zależnościowe muszą uwzględniać te zależności, co komplikuje analizę składniową.

14.1. Problemy tokenizacji

Tokenizacja tekstu polskiego natrafia na specyficzne trudności związane z obecnością aglutynacji w niektórych formach wyrazowych. Partykuły enklityczne, takie jak "-by", "-bym" czy "-byś", mogą być dołączane do różnych form wyrazowych. Podział na tokeny musi uwzględniać te zjawiska morfologiczne.

Nazwy złożone i wielowyrazowe jednostki leksykalne stanowią kolejne wyzwanie. Nazwy własne złożone z wielu wyrazów, nazwy instytucji, tytuły prac czy nazwy geograficzne powinny być traktowane jako całości podczas analizy semantycznej. Automatyczne rozpoznawanie wielowyrazowych jednostek leksykalnych jest zadaniem wymagającym zarówno zasobów leksykalnych, jak i modeli kontekstowych.

Pisownia łączna i rozdzielna wyrazów złożonych jest źródłem niejednoznaczności. Wiele wyrazów może być zapisywanych zarówno łącznie, jak i rozdzielnie, w zależności od kontekstu użycia. System analizy tekstu musi radzić sobie z wariantami pisowni, które odpowiadają tej samej jednostce leksykalnej.

14.2. Zasoby dla języka polskiego

Krajowy Korpus Języka Polskiego jest największym publicznie dostępnym zbiorem tekstów polskich. Zawiera teksty z różnych dziedzin i gatunków, zbalansowane pod względem chronologicznym i tematycznym. Korpus jest opatrzony anotacją morfologiczną, co czyni go cennym zasobem dla trenowania i ewaluacji modeli.

Polskie drzewbanki, czyli zbiory tekstów opatrzone anotacją składniową, są dostępne w mniejszej liczbie niż dla języka angielskiego. Polskie Drzewbanki Zależnościowe zawierają kilkadziesiąt tysięcy zdań z ręczną anotacją struktur zależnościowych. Zasoby te są kluczowe dla trenowania wysokiej jakości parserów.

WordNet dla języka polskiego, znany jako Słowosieć, dostarcza informacji o relacjach semantycznych między wyrazami. Relacje takie jak synonimia, hiponimia i meronamia są zorganizowane w strukturę sieciową. Słowosieć jest regularnie rozszerzana i uzupełniana przez badaczy z Politechniki Wrocławskiej.

15. Implementacja i optymalizacja systemu

Implementacja systemu analizy tekstu wymaga starannego projektowania architektury oprogramowania. Modułowa budowa systemu ułatwia testowanie, konserwację i rozbudowę. Każdy moduł powinien mieć jasno zdefiniowany interfejs i odpowiedzialność.

Potok przetwarzania, zwany pipeline, organizuje kolejność wykonywania operacji analitycznych. Dane przepływają przez kolejne etapy, z których każdy transformuje lub wzbogaca dane wejściowe. Ważna jest efektywna propagacja błędów i mechanizmy odtwarzania po awarii poszczególnych etapów.

Przetwarzanie wsadowe jest preferowane dla dużych zbiorów dokumentów ze względu na efektywność. Przetwarzanie strumieniowe jest konieczne w przypadku aplikacji wymagających odpowiedzi w czasie rzeczywistym. Wybór między tymi podejściami zależy od wymagań dotyczących opóźnień i przepustowości.

15.1. Optymalizacja wydajności

Profilowanie kodu jest pierwszym krokiem optymalizacji. Identyfikacja wąskich gardeł pozwala na skoncentrowanie wysiłków optymalizacyjnych w miejscach, gdzie przyniesie to największy efekt. Przedwczesna optymalizacja bez profilowania może prowadzić do trudnego w utrzymaniu kodu bez wymiernej poprawy wydajności.

Wektoryzacja obliczeń, czyli zastąpienie pętli operacjami macierzowymi, znacząco przyspiesza przetwarzanie na sprzęcie obsługującym równoległe obliczenia. Biblioteki numeryczne, takie jak NumPy i PyTorch, są zoptymalizowane pod kątem wydajnych operacji macierzowych. Operacje wykonywane na procesorach graficznych są często dziesiątki razy szybsze niż te same operacje na procesorach ogólnego przeznaczenia.

Buforowanie wyników częstych operacji zmniejsza liczbę koniecznych obliczeń. Wyniki analizy morfologicznej dla najczęstszych form wyrazowych mogą być przechowywane w pamięci podręcznej. Rozmiar bufora musi być dobrany tak, aby nie powodował nadmiernego zużycia pamięci.

15.2. Skalowalność i wdrożenie

Skalowalność pozioma, polegająca na dodawaniu kolejnych węzłów obliczeniowych, jest preferowaną strategią dla systemów przetwarzających duże wolumeny danych. Architektura mikroserwisów umożliwia niezależne skalowanie poszczególnych komponentów systemu. Orkiestrator kontenerów zarządza rozmieszczeniem i skalowaniem usług.

Monitorowanie systemu produkcyjnego jest niezbędne dla zapewnienia jego niezawodności. Metryki takie jak czas odpowiedzi, przepustowość, zużycie zasobów i liczba błędów powinny być zbierane i analizowane na bieżąco. Alerty powinny być konfigurowane dla wartości progowych wykraczających poza normalne zakresy.

Aktualizacja modeli produkcyjnych wymaga starannego planowania. Wdrożenie nowej wersji modelu powinno być poprzedzone testami na reprezentatywnym zbiorze danych. Techniki wdrożeniowe takie jak canary release czy blue-green deployment minimalizują ryzyko zakłócenia działania systemu podczas aktualizacji.

16. Studia przypadków

W ramach badań przeprowadzono trzy studia przypadków ilustrujące praktyczne zastosowanie opracowanego systemu. Każde studium dotyczyło innego rodzaju dokumentów i innego zestawu zadań analitycznych. Wyniki studiów przypadków uzupełniają wyniki eksperymentów ilościowych o perspektywę jakościową.

16.1. Analiza artykułów medycznych

Pierwsze studium przypadku dotyczyło analizy artykułów z zakresu medycyny klinicznej. Dokumenty te charakteryzują się specyficznym słownictwem, licznymi skrótami i akronimami oraz odwołaniami do standardów klinicznych. Ekstrakcja informacji o metodologii badań, charakterystyce grup badanych i wynikach klinicznych stanowiła główne zadanie analityczne.

Wyniki analizy wskazały na wysoką częstość użycia strony biernej w opisach procedur metodologicznych. Zdania takie jak "pacjentom podawano" lub "próbki pobierano" są typowe dla stylu naukowego w medycynie. System prawidłowo klasyfikował te konstrukcje jako biernik, nie zaś jako formy bezosobowe.

Niezdefiniowane akronimy stanowiły istotny problem w analizowanych artykułach medycznych. Niektóre z nich były specyficzne dla danej specjalności medycznej i nie były wyjaśniane przez autorów, zakładając ich znajomość przez czytelników z tej dziedziny. System flagował je jako błędy, co w kontekście specjalistycznej publikacji mogło prowadzić do fałszywych alarmów.

16.2. Analiza tekstów prawniczych

Drugie studium przypadku obejmowało analizę aktów prawnych i orzeczeń sądowych. Teksty prawnicze posiadają specyficzną składnię z długimi zdaniami złożonymi, licznymi klauzulami warunkowymi i odsyłaczami do innych przepisów. Analiza zależnościowa tych tekstów była szczególnie wymagająca ze względu na ich złożoność składniową.

Długość zdań w tekstach prawniczych znacząco przekraczała średnią dla korpusu ogólnego. Zdania liczące ponad pięćdziesiąt tokenów nie były rzadkością. Parser zależnościowy miał trudności z prawidłową analizą tak długich struktur, co przekładało się na niższą jakość ekstrakcji informacji.

Tryb rozkazujący i bezokolicznik z modalnym znaczeniem obowiązku lub zakazu są charakterystyczne dla języka prawniczego. Konstrukty takie jak "strona jest zobowiązana do" lub "zabrania się" wymagają odrębnej obsługi w algorytmach wykrywania form osobowych. System musiał odróżniać te konstrukcje od rzeczywistego użycia form osobowych.

16.3. Analiza recenzji naukowych

Trzecie studium dotyczyło analizy anonimowych recenzji artykułów naukowych. Recenzje charakteryzują się mieszanym stylem: częściowo bezosobowym przy opisie stwierdzonych problemów, a częściowo personalnym przy wyrażaniu opinii. Wykrywanie ocen pozytywnych i negatywnych oraz identyfikacja konkretnych zarzutów merytorycznych były głównymi zadaniami.

Użycie form osobowych okazało się w recenzjach znacznie częstsze niż w artykułach naukowych. Recenzenci często używali form takich jak "uważam", "sądzę" czy "moim zdaniem". System prawidłowo flagował te użycia jako potencjalne błędy stylistyczne, choć w kontekście recenzji są one powszechnie akceptowane.

Analiza sentymentu recenzji naukowych jest zadaniem trudniejszym niż analiza recenzji produktów konsumenckich. Recenzje naukowe zawierają zarówno pozytywne, jak i negatywne elementy w odniesieniu do tej samej pracy. Zdania o pozornie negatywnym wydźwięku mogą prowadzić do pozytywnej konkluzji i na odwrót.

Podsumowanie

Niniejsza praca przedstawiła kompleksowe podejście do automatycznej analizy języka w dokumentach naukowych. Opracowany system łączy metody analizy morfologicznej, składniowej i semantycznej z regułami dotyczącymi stylu naukowego. Wyniki eksperymentów potwierdzają skuteczność zaproponowanego podejścia.

Najważniejszym wkładem pracy jest opracowanie modułu wykrywającego naruszenia stylu naukowego, ze szczególnym uwzględnieniem użycia form osobowych i niespójnego stosowania akronimów. Moduł ten może być zintegrowany z dowolnym edytorem tekstu jako wtyczka wspierająca autorów w czasie rzeczywistym.

Ograniczenia przedstawionego podejścia wynikają przede wszystkim z niedoskonałości bazowych narzędzi analizy językowej. Błędy analizy morfologicznej i składniowej propagują się do wyższych warstw systemu. Poprawa jakości bazowych narzędzi NLP dla języka polskiego jest warunkiem koniecznym dla dalszego podniesienia skuteczności systemu.

Przyszłe prace powinny skupić się na rozszerzeniu systemu o obsługę dodatkowych typów błędów stylistycznych, takich jak nadmierna nominalizacja, użycie strony biernej w nieodpowiednich kontekstach czy brak spójności terminologicznej. Integracja z systemami zarządzania literaturą naukową mogłaby dodatkowo zwiększyć wartość narzędzia dla użytkowników końcowych.

17. Ocena jakości generowania tekstu naukowego

Ocena jakości automatycznie generowanych tekstów naukowych jest zagadnieniem metodologicznie złożonym. Tradycyjne metryki, takie jak BLEU czy ROUGE, oparte na porównaniu z tekstami referencyjnymi, nie oddają w pełni jakości tekstu z perspektywy stylu naukowego. Konieczne jest opracowanie dedykowanych metryk uwzględniających specyficzne wymagania stylistyczne.

Kompetentni oceniający ludzcy są złotym standardem w ocenie jakości generowanych tekstów. Badania z udziałem ekspertów z danej dziedziny pozwalają na ocenę merytorycznej poprawności i adekwatności terminologicznej wygenerowanych fragmentów. Jednak ocena ludzka jest kosztowna i trudna do skalowania na duże zbiory tekstów.

Korelacja między automatycznymi metrykami a oceną ludzką jest jednym z kluczowych zagadnień badawczych. Wykazano, że metryki oparte na modelach językowych, takie jak BERTScore, lepiej korelują z oceną ludzką niż metryki oparte na n-gramach. Dla języka polskiego kalibracja tych metryk z oceną ludzką jest obszarem wymagającym dalszych badań.

17.1. Spójność terminologiczna

Spójność terminologiczna polega na konsekwentnym użyciu tych samych terminów na określenie tych samych pojęć w całym dokumencie. Niespójność terminologiczna wprowadza czytelnika w błąd i utrudnia automatyczne przetwarzanie tekstu. Systemy sprawdzania spójności terminologicznej mogą automatycznie identyfikować przypadki, w których to samo pojęcie jest opisywane różnymi terminami.

Słowniki terminologiczne dziedzinowe stanowią punkt odniesienia dla oceny spójności terminologicznej. Dla wielu dziedzin dostępne są zatwierdzone słowniki terminologiczne, zarówno w języku polskim, jak i w wersji dwujęzycznej. Automatyczne mapowanie terminów użytych w tekście na terminy ze słownika pozwala na identyfikację przypadków niestandardowego użycia.

Zarządzanie terminologią w długich dokumentach, takich jak monografie czy rozprawy doktorskie, jest szczególnie ważne. Autorzy często nieświadomie używają różnych terminów na opisanie tego samego pojęcia w różnych rozdziałach. Narzędzia wspomagające spójność terminologiczną mogą sygnalizować takie przypadki i proponować ujednolicenie.

17.2. Automatyczna korekta stylu

Automatyczna korekta stylu naukowego jest zadaniem wykraczającym poza prostą detekcję błędów. System musi nie tylko wskazać problem, ale też zaproponować poprawioną wersję tekstu. Generowanie alternatywnych sformułowań wymaga modeli zdolnych do rozumienia kontekstu i generowania płynnych parafraz zachowujących znaczenie.

Przekształcanie zdań z formy osobowej na bezosobową lub bierną jest konkretnym zadaniem korekty stylu. Zdanie "Przeprowadziłam eksperyment" może zostać przekształcone w "Przeprowadzono eksperyment" lub "Eksperyment został

przeprowadzony". Wybór między tymi wariantami zależy od kontekstu i preferencji redakcyjnych.

Zachowanie znaczenia podczas automatycznej korekty stylu jest kluczowym wymogiem. Zmiana formy gramatycznej nie może wpływać na treść merytoryczną zdania. Mechanizmy weryfikacji semantycznej powinny być stosowane po każdej automatycznej transformacji, aby upewnić się, że sens zdania nie uległ zmianie.

18. Integracja z istniejącymi ekosystemami narzędziowymi

Współczesne środowiska badawcze korzystają z szerokiej gamy narzędzi wspierających pracę naukową. Zarządzanie literaturą, edycja tekstu, analiza danych i prezentacja wyników są obsługiwane przez specjalistyczne oprogramowanie. Integracja narzędzi analizy języka z tymi ekosystemami zwiększa ich użyteczność praktyczną.

Menedżery literatury, takie jak Zotero czy Mendeley, przechowują bibliografie i pełne teksty artykułów. Integracja z systemem analizy tekstu mogłaby umożliwić automatyczną ekstrakcję informacji z zarządzanych dokumentów. Wyniki analizy mogłyby być dołączane jako metadane do rekordów bibliograficznych.

Platformy do kolaboratywnego pisania umożliwiają wielu autorom pracę nad tym samym dokumentem jednocześnie. Integracja narzędzi stylistycznych z takimi platformami pozwoliłaby na bieżącą ocenę stylu podczas pisania. Sugestie poprawek wyświetlane inline nie zakłócają przepływu pracy twórczej.

18.1. Interfejsy programistyczne

Projektowanie interfejsów programistycznych dla narzędzi analizy tekstu wymaga uwzględnienia potrzeb różnorodnych grup użytkowników. Deweloperzy aplikacji oczekują stabilnych, wersjonowanych API z wyczerpującą dokumentacją. Naukowcy danych preferują interaktywne notebooki i biblioteki z intuicyjnym interfejsem. Użytkownicy końcowi potrzebują prostych interfejsów graficznych bez konieczności programowania.

Dokumentacja API powinna zawierać przykłady użycia dla typowych scenariuszy. Referencja API opisująca wszystkie dostępne metody i parametry jest niezbędna, ale niewystarczająca. Przewodniki tematyczne wyjaśniające, jak realizować konkretne zadania, znacząco obniżają próg wejścia dla nowych użytkowników.

Obsługa błędów i informacje diagnostyczne są kluczowymi elementami dobrego API. Komunikaty błędów powinny być jasne, informować o przyczynie problemu i wskazywać możliwe rozwiązania. Kody błędów powinny być spójne i zgodne z konwencjami przyjętymi w danym ekosystemie technologicznym.

18.2. Standardy wymiany danych

Standardy wymiany danych lingwistycznych, takie jak NAF, CoNLL czy WebAnno, ułatwiają interoperacyjność między narzędziami. Stosowanie standardowych formatów umożliwia tworzenie potoków przetwarzania składających się z narzędzi różnych producentów. Brak standaryzacji był historycznie jedną z przeszkód w rozwoju ekosystemów NLP.

Formaty oparte na XML, takie jak TEI, są szeroko stosowane do reprezentacji zasobów językowych. Format ten umożliwia zakodowanie zarówno treści, jak i bogatej anotacji lingwistycznej. Narzędzia do przetwarzania XML są dostępne w praktycznie każdym języku programowania, co ułatwia integrację.

Lekkie formaty oparte na JSON zyskują popularność ze względu na łatwość przetwarzania w nowoczesnych aplikacjach webowych. Format JSONL, w którym każda linia zawiera niezależny obiekt JSON, jest szczególnie wygodny do przesyłania strumieniowego dużych zbiorów adnotowanych tekstów. Kompresja takich plików przed przesłaniem przez sieć jest zalecana ze względu na ich potencjalnie dużą objętość.

19. Analiza korpusowa i statystyki językowe

Analiza korpusowa dostarcza ilościowych danych o użyciu języka w rzeczywistych tekstach. Częstość wyrazów, rozkład długości zdań, proporcja różnych części mowy oraz wzorce kolokacyjne są mierzalne i pozwalają na obiektywną charakterystykę stylu danego gatunku tekstu. Porównanie statystyk różnych gatunków ujawnia ich charakterystyczne cechy językowe.

Rozkład długości zdań w tekstach naukowych różni się od rozkładów obserwowanych w tekstach potocznych czy literackich. Zdania naukowe są przeciętnie dłuższe i bardziej złożone pod względem składniowym. Odchylenie standardowe długości zdań jest jednak również wyższe, co odzwierciedla zróżnicowanie między zdaniami prostymi a wielokrotnie złożonymi.

Zagęszczenie leksykalne, mierzone jako stosunek wyrazów znaczących do ogółu wyrazów, jest wyższe w tekstach naukowych niż w tekstach mówionych. Autorzy tekstów naukowych dążą do precyzji, używając terminów specjalistycznych zamiast opisowych omówień. Wysoka gęstość leksykalna sprawia, że teksty naukowe są trudniejsze w odbiorze dla laika.

19.1. Analiza n-gramów

N-gramy, czyli sekwencje n kolejnych tokenów, stanowią podstawowy element analizy statystycznej tekstu. Unigramy, czyli pojedyncze tokeny, dostarczają informacji o słownictwie. Bigramy i trigramy ujawniają typowe kolokacje i wzorce syntaktyczne. Analiza n-gramów jest stosowana w modelu językowym, wykrywaniu plagiatu i klasyfikacji tekstu.

Miara tf-idf, czyli częstotliwość terminu ważona odwrotną częstotliwością dokumentu, jest klasyczną metodą wydobywania słów kluczowych z dokumentu. Słowa często pojawiające się w danym dokumencie, ale rzadko w całym korpusie, są uznawane za charakterystyczne dla tego dokumentu. Miara ta jest szeroko stosowana w wyszukiwaniu informacji i analizie tematycznej.

Modele językowe oparte na n-gramach były standardem przed erą sieci neuronowych. Mimo swojej prostoty wciąż są używane w zastosowaniach wymagających niskiego opóźnienia i małego rozmiaru modelu. Wygładzanie rozkładu prawdopodobieństwa dla niewidzianych n-gramów jest kluczowym problemem w tych modelach.

19.2. Modelowanie tematyczne

Modelowanie tematyczne, czyli topic modeling, jest techniką eksploracyjnej analizy dużych zbiorów tekstów. Algorytm identyfikuje zbiory wyrazów, które często współwystępują, interpretując je jako tematy. Każdy dokument jest reprezentowany jako mieszanina tematów z różnymi wagami.

Algorytm latentnej alokacji Dirichleta jest najszerzej stosowaną metodą modelowania tematycznego. Zakłada on, że każdy temat jest rozkładem prawdopodobieństwa nad wyrazami, a każdy dokument jest rozkładem prawdopodobieństwa nad tematami. Uczenie parametrów odbywa się metodami wnioskowania bayesowskiego.

Interpretacja wyników modelowania tematycznego wymaga udziału eksperta dziedzinowego. Automatycznie wykryte tematy mogą nie odpowiadać semantycznie znaczącym kategoryzacjom. Ocena jakości modelu tematycznego obejmuje zarówno miary ilościowe, jak perplexity czy spójność tematyczna, jak i ocenę jakościową przez ekspertów.

20. Zarządzanie wiedzą i reprezentacja ontologiczna

Ontologie formalne dostarczają precyzyjnych definicji pojęć i relacji między nimi w danej dziedzinie. W przetwarzaniu języka naturalnego ontologie są używane jako zasoby wiedzy wspierające rozumienie semantyczne tekstu. Ekstrakcja informacji ukierunkowana ontologią polega na poszukiwaniu w tekście instancji pojęć i relacji zdefiniowanych w ontologii.

Budowanie ontologii jest procesem żmudnym i wymagającym ekspertyzy zarówno w danej dziedzinie, jak i w formalnych metodach reprezentacji wiedzy. Automatyczne metody indukcji ontologii z tekstu mogą przyspieszyć ten proces, jednak ich wyniki wymagają weryfikacji przez ekspertów. Podejście półautomatyczne, łączące metody komputerowe z ręczną weryfikacją, jest najczęściej stosowane w praktyce.

Grafy wiedzy, takie jak Wikidata czy DBpedia, są wielkoskalowymi bazami wiedzy reprezentującymi fakty w postaci trójek podmiot-predykat-obiekt. Łączenie encji wymienionych w tekście z węzłami w grafie wiedzy jest zadaniem zwanym linkowaniem encji. Umożliwia ono wzbogacenie wydobytej informacji o wiedzę kontekstową z bazy wiedzy.

20.1. Ekstrakcja relacji

Ekstrakcja relacji polega na identyfikacji semantycznych zależności między encjami wymienionymi w tekście. Relacje takie jak "jest-częścią", "jest-rodzajem", "spowodował" czy "jest-zatrudnionym-przez" są typowymi relacjami ekstrahowanymi z tekstów. Wyniki ekstrakcji relacji mogą być automatycznie dodawane do grafów wiedzy, wzbogacając je o nowe fakty.

Nadzorowane metody ekstrakcji relacji wymagają przykładów anotowanych par encji i relacji między nimi. Liczba wymaganych przykładów zależy od złożoności relacji i różnorodności jej wyrażeń językowych. Uczenie ze słabym nadzorem, w którym anotacja jest generowana automatycznie za pomocą wzorców, zmniejsza koszt przygotowania danych treningowych.

Metody oparte na regułach ekstrakcji relacji są precyzyjne, ale mają niskie pokrycie. Reguły muszą być ręcznie tworzone przez ekspertów i pokrywają jedynie wcześniej przewidziane wzorce językowe. Metody uczenia maszynowego mają wyższe pokrycie, ale niższą precyzję. Połączenie obu podejść daje zwykle najlepsze wyniki praktyczne.

20.2. Wnioskowanie na grafach wiedzy

Grafy wiedzy umożliwiają wnioskowanie o faktach, które nie są explicite zapisane, lecz wynikają z istniejących relacji. Wnioskowanie dedukcyjne na podstawie reguł logicznych pozwala na automatyczne uzupełnienie grafu o nowe fakty. Metody indukcyjne, oparte na wzorcach statystycznych w grafie, są bardziej skalowalne, lecz mniej precyzyjne.

Reprezentacje wektorowe węzłów i krawędzi grafu, zwane embedingami grafu, umożliwiają zastosowanie metod uczenia maszynowego do zadań wnioskowania na grafach. Modele takie jak TransE, DistMult czy ComplEx odwzorowują encje i relacje w przestrzeni wektorowej i przewidują brakujące trójki na podstawie regularności geometrycznych.

Integracja grafów wiedzy z modelami językowymi jest aktywnym obszarem badań. Modele językowe wzbogacone o wiedzę faktograficzną lepiej radzą sobie z pytaniami wymagającymi konkretnej wiedzy o świecie. Metody injektowania wiedzy do modeli językowych obejmują fine-tuning na danych z grafu wiedzy oraz architektury z zewnętrzną pamięcią.

21. Ewaluacja systemów pytań i odpowiedzi

Systemy pytań i odpowiedzi, zwane systemami QA, automatycznie odpowiadają na pytania zadane w języku naturalnym. Pytanie jest analizowane pod kątem jego typu i oczekiwanego rodzaju odpowiedzi. System przeszukuje bazę wiedzy lub zbiór dokumentów w celu znalezienia fragmentu zawierającego odpowiedź.

Systemy QA oparte na ekstrakcji wydobywają odpowiedź bezpośrednio z tekstu, nie generując jej od podstaw. Zadanie polega na wskazaniu zakresu tekstu zawierającego odpowiedź na pytanie. Modele transformerowe, takie jak architektura oparta na zadaniu pytanie-odpowiedź, osiągają bardzo wysoką dokładność na standardowych zbiorach testowych.

Generatywne systemy QA tworzą odpowiedź na podstawie przeczytanych dokumentów, nie ograniczając się do dosłownego cytowania. Odpowiedź może być syntezą informacji z wielu źródeł. Weryfikacja faktograficzna wygenerowanych odpowiedzi jest trudna i wymaga dodatkowych mechanizmów kontroli jakości.

21.1. Zbiory testowe dla systemów QA

SQuAD, czyli Stanford Question Answering Dataset, jest jednym z najszerzej stosowanych zbiorów do ewaluacji systemów QA. Zawiera pytania zadane przez ludzi do artykułów Wikipedii wraz z zaznaczonymi odpowiedziami w tekście. Trudniejsza wersja zbioru zawiera pytania, na które odpowiedź nie jest zawarta w tekście, co wymaga od systemu rozpoznania granic swojej wiedzy.

Dla języka polskiego dostępność zbiorów ewaluacyjnych dla zadań QA jest ograniczona. Tłumaczenia istniejących zbiorów anglojęzycznych nie w pełni oddają specyfikę języka polskiego. Tworzenie oryginalnych polskich zbiorów ewaluacyjnych jest priorytetem dla polskiej społeczności NLP.

Wielojęzyczne zbiory ewaluacyjne umożliwiają porównanie systemów w różnych językach. Różnice w wynikach między językami ujawniają, dla których języków modele są mniej dopracowane. Systematyczne porównania między językami motywują do inwestowania w zasoby dla mniej zasobnych języków.

21.2. Wyzwania w systemach QA dla polskiego

Pytania w języku polskim mogą mieć różne struktury gramatyczne wyrażające ten sam sens. Bogata fleksja sprawia, że to samo pytanie może być sformułowane na wiele sposobów. System QA musi rozumieć intencję pytania niezależnie od jego formy gramatycznej.

Rozumienie zaimków i koreferencji jest kluczowe dla prawidłowej odpowiedzi na pytania dotyczące wcześniej wspomnianych bytów. Zdania następujące po sobie często zawierają zaimki odnoszące się do wcześniej wprowadzonych pojęć. System musi śledzić te odniesienia, aby prawidłowo zinterpretować kontekst pytania.

Pytania złożone, wymagające agregacji informacji z wielu miejsc w tekście, są szczególnie trudne dla systemów ekstrakcji odpowiedzi. System musi nie tylko znaleźć odpowiednie fragmenty, ale też zintegrować zawarte w nich informacje. Zadanie to wymaga zaawansowanego rozumowania na poziomie dyskursu.

22. Podsumowanie techniczne i zalecenia implementacyjne

Wybór narzędzi do przetwarzania języka polskiego powinien być podyktowany wymaganiami konkretnego zadania. Nie istnieje jedno narzędzie optymalne dla wszystkich przypadków użycia. Kompromis między jakością, szybkością i kosztem obliczeniowym musi być oceniony w kontekście docelowej aplikacji.

Dla zadań wymagających wysokiej precyzji morfologicznej zalecane jest stosowanie Morfeusza2 jako weryfikatora wyników modeli opartych na uczeniu maszynowym. Dla zadań wymagających szybkiego przetwarzania dużych wolumenów danych preferowane są lżejsze modele z ewentualną post-hoc weryfikacją wybranych wyników.

Budowanie potoków przetwarzania powinno uwzględniać możliwość wymiany poszczególnych komponentów bez konieczności przepisywania całości. Standaryzowane interfejsy między komponentami i ujednolicone formaty danych pośrednich ułatwiają eksperymenty z różnymi konfiguracjami narzędzi. Architektura modułowa jest inwestycją, która procentuje w długim terminie.

22.1. Dobre praktyki implementacyjne

Reprodukowalność eksperymentów jest fundamentalną zasadą badań naukowych. Każdy eksperyment powinien być przeprowadzany z ustalonym ziarnem losowości, a wszystkie użyte zasoby i narzędzia powinny być precyzyjnie wersjonowane. Skrypty automatyzujące przebieg eksperymentu ułatwiają ich powtórzenie przez innych badaczy.

Testowanie jednostkowe komponentów systemu NLP jest często zaniedbywane ze względu na trudność w definiowaniu oczekiwanych wyników dla zadań językowych. Jednak nawet przybliżone testy, sprawdzające czy dane wyjściowe mają oczekiwany kształt i mieszczą się w rozsądnych zakresach, są lepsze niż brak testów. Systematyczne testowanie zmniejsza ryzyko regresji przy wprowadzaniu zmian.

Dokumentacja kodu i modeli jest inwestycją, która zwraca się przy każdym powrocie do projektu po dłuższej przerwie. Szczególnie ważne jest dokumentowanie nieintuicyjnych decyzji projektowych i ich uzasadnienia. Komentarze wyjaśniające "dlaczego" są cenniejsze niż komentarze opisujące "co" robi kod.

22.2. Wskazówki dla autorów tekstów naukowych

Styl naukowy wymaga precyzji i jednoznaczności w wyrażaniu myśli. Każde zdanie powinno nieść konkretną informację. Ogólniki i sformułowania bez pokrycia w danych osłabiają wiarygodność pracy. Czytelnik powinien móc zweryfikować każde twierdzenie na podstawie przytoczonych dowodów.

Konsekwentne używanie czasów gramatycznych jest jednym z elementów spójności stylistycznej. W opisie metodologii powszechnie stosowany jest czas przeszły, podczas gdy w opisie wyników i dyskusji może być używany zarówno czas przeszły, jak i teraźniejszy. Ważne jest, aby wybrany schemat był stosowany konsekwentnie w całej pracy.

Akronimy i skróty powinny być zawsze definiowane przy pierwszym użyciu, niezależnie od tego, jak powszechnie są znane w danej dziedzinie. Praca może być czytana przez osoby spoza wąskiej specjalności autora. Konsekwentne definiowanie akronimów jest dobrą praktyką, która zwiększa dostępność tekstu i ułatwia jego automatyczne przetwarzanie.

Wnioski powinny wynikać bezpośrednio z przedstawionych wyników. Uogólnienia wykraczające poza zakres przeprowadzonych badań powinny być wyraźnie oznaczone jako spekulacje lub hipotezy do weryfikacji. Rozgraniczenie między udowodnionym a postulowanym jest kluczowe dla zachowania rzetelności naukowej.

23. Analiza sentymentu w tekstach akademickich

Analiza sentymentu w tekstach naukowych różni się zasadniczo od analizy sentymentu w recenzjach produktów czy wpisach w mediach społecznościowych. Teksty naukowe stosują stonowany, obiektywny język, w którym nawet negatywne oceny są formułowane ostrożnie i z pełną argumentacją. Bezpośrednie wyrażenia emocji są w tym gatunku rzadkie i zazwyczaj nieakceptowalne.

Wykrywanie hedging, czyli zdań wyrażających niepewność lub ostrożność, jest zadaniem specyficznym dla tekstów naukowych. Wyrażenia takie jak "wydaje się", "można przypuszczać", "wyniki sugerują" czy "jest prawdopodobne" wskazują na stopień pewności autora co do prezentowanych wniosków. Automatyczna identyfikacja hedgingu pozwala na lepsze rozumienie stopnia pewności twierdzeń w tekście.

Boosting, czyli wzmacnianie twierdzeń, jest przeciwieństwem hedgingu. Wyrażenia takie jak "wyraźnie pokazuje", "jednoznacznie dowodzi" czy "bez wątpienia wskazuje" są używane, gdy autor jest szczególnie pewny swoich wniosków. Zarówno hedging, jak i boosting są ważnymi elementami retoryki naukowej i powinny być uwzględniane w modelach stylu naukowego.

23.1. Metawypowiedzi w tekstach naukowych

Metawypowiedzi to fragmenty tekstu, w których autor komentuje własny dyskurs lub odwołuje się do struktury pracy. Wyrażenia takie jak "jak wspomniano wcześniej", "w kolejnym rozdziale", "wróćmy do" czy "podsumowując" pełnią funkcję metatekstową. Automatyczne rozpoznawanie metawypowiedzi ułatwia analizę struktury retorycznej tekstu.

Wskaźniki dyskursowe, zwane też spójnikami logicznymi, organizują relacje między zdaniami i akapitami. Wyrażenia przyczynowe, przeciwstawne, wyliczające i podsumowujące tworzą koherentną strukturę argumentacji. Analiza rozmieszczenia wskaźników dyskursowych może ujawnić typowe wzorce argumentacyjne dla danego gatunku tekstu.

23.2. Cytowania i atrybucja twierdzeń

Cytowania w tekstach naukowych pełnią funkcję atrybucji twierdzeń do ich źródeł. Twierdzenie opatrzone odwołaniem do literatury jest prezentowane jako fakt uznany przez społeczność naukową. Twierdzenie bez cytowania jest rozumiane jako własny wkład autora lub powszechnie znany fakt niewymagający uzasadnienia.

Styl cytowania różni się w zależności od konwencji przyjętych w danej dyscyplinie. W naukach przyrodniczych powszechny jest system numeryczny, gdzie cytowania są oznaczane numerami w nawiasach kwadratowych. W naukach humanistycznych częsty jest system nazwisko-rok, gdzie cytowania zawierają nazwisko autora i rok publikacji.

Automatyczna ekstrakcja informacji bibliograficznych z tekstu jest zadaniem o wysokim znaczeniu praktycznym. Systemy zarządzania literaturą mogą korzystać z tej technologii do automatycznego importowania cytowań z dokumentów PDF. Rozpoznawanie różnych stylów cytowania jest konieczne ze względu na ich dużą różnorodność między dyscyplinami i wydawnictwami.

24. Perspektywy wielojęzyczności i transferu wiedzy

Modele wielojęzyczne, trenowane jednocześnie na danych z wielu języków, zyskują na popularności ze względu na oszczędność zasobów obliczeniowych i możliwość transferu wiedzy między językami. Model mXLM-R czy mBERT osiągają akceptowalne wyniki dla dziesiątek języków, w tym dla polskiego, bez konieczności trenowania oddzielnego modelu dla każdego języka.

Transfer uczenia polega na fine-tuningu modelu wytrenowanego na dużym zbiorze ogólnym na mniejszym zbiorze specyficznym dla danego zadania. Technika ta pozwala na osiągnięcie dobrych wyników przy małej liczbie danych anotowanych. Jest szczególnie cenna dla języków o ograniczonych zasobach, takich jak wiele języków słowiańskich poza rosyjskim.

Zero-shot transfer umożliwia zastosowanie modelu wytrenowanego w jednym języku do przetwarzania tekstu w innym języku bez żadnych danych treningowych w języku docelowym. Wyniki są zazwyczaj gorsze niż przy pełnym fine-tuningu, jednak mogą być wystarczające dla zastosowań, gdzie koszt tworzenia danych treningowych jest prohibicyjny.

24.1. Dostosowanie domeny

Dostosowanie modelu językowego do konkretnej dziedziny, zwane domain adaptation, polega na dalszym trenowaniu modelu ogólnego na tekstach z danej dziedziny. Modele biomedyczne, prawnicze czy finansowe, wytrenowane na specjalistycznych korpusach, osiągają lepsze wyniki w tych dziedzinach niż modele ogólne.

Ciągłe uczenie, znane jako continual learning, pozwala na aktualizację modelu w miarę napływu nowych danych bez utraty wcześniej nabytej wiedzy. Problem katastroficznego zapominania, polegający na utracie wcześniejszej wiedzy przy uczeniu nowych zadań, jest aktywnym obszarem badań. Metody regularyzacji i architektur modularnych pozwalają częściowo złagodzić ten problem.

Ocena modeli po dostosowaniu do domeny wymaga specyficznych dla domeny zbiorów testowych. Benchmarki ogólne mogą nie odzwierciedlać poprawy jakości w wąskiej dziedzinie. Tworzenie dziedzinowych zbiorów ewaluacyjnych jest kosztowne, ale niezbędne dla rzetelnej oceny jakości dostosowania.

24.2. Modele dla języków o ograniczonych zasobach

Języki o ograniczonych zasobach cyfrowych, takie jak wiele języków afrykańskich, azjatyckich czy języki mniejszości etnicznych, są niedostatecznie reprezentowane w istniejących modelach językowych. Metody transferu z języków o bogatszych zasobach, tworzenie syntetycznych danych treningowych oraz crowdsourcing anotacji są stosowane w celu poprawy jakości modeli dla tych języków.

Język polski, choć dysponuje relatywnie bogatymi zasobami cyfrowymi w porównaniu do wielu innych języków, nadal ustępuje językowi angielskiemu pod względem liczby i różnorodności dostępnych zasobów. Inicjatywy takie jak CLARIN-PL, które agregują i standaryzują zasoby językowe dla polszczyzny, są kluczowe dla rozwoju polskiego NLP.

Współpraca między ośrodkami akademickimi jest niezbędna dla efektywnego wykorzystania ograniczonych zasobów. Dzielenie się zbiorami danych, modelami i narzędziami między instytucjami przyspiesza postęp badań. Inicjatywy open source w polskim NLP pozwalają na budowanie na wcześniejszych pracach zamiast powtarzania wysiłków.

25. Błędy typowe w pracach naukowych – dodatkowe przykłady

25.1. Kolejne przykłady formy osobowej

Uważam, że model osiąga lepsze wyniki niż konkurencyjne rozwiązania. Zamiast oceny subiektywnej należy przytoczyć konkretne liczby.

W tej pracy pokazuję, jak zastosować metody uczenia maszynowego do analizy stylu. Preferowana jest forma: "W niniejszej pracy przedstawiono zastosowanie..."

Odkryłam, że częstość użycia strony biernej koreluje z poziomem formalności tekstu. Forma przeszła pierwszej osoby jest równie niezalecana.

Zdecydowałam się na zastosowanie tego modelu ze względu na jego skuteczność. Decyzje metodologiczne powinny być uzasadniane obiektywnie.

Przeprowadziliśmy testy na zbiorze stu dokumentów i zaobserwowaliśmy poprawę wyników. Forma bezosobowa: "Testy przeprowadzono na zbiorze stu dokumentów, a wyniki uległy poprawie."

Wierzymy, że zaproponowane podejście otworzy nowe możliwości badawcze w tej dziedzinie. Wyrażenia wiary i przekonania są nieodpowiednie w stylu naukowym.

25.2. Dodatkowe przykłady niezdefiniowanych akronimów

Architektura RPA została zastosowana do automatyzacji przetwarzania dokumentów wejściowych. Narzędzia tego rodzaju są coraz szerzej stosowane w środowiskach korporacyjnych.

Klasyfikator SVM osiągnął precyzję na poziomie osiemdziesięciu siedmiu procent. Wynik ten jest porównywalny z wynikami nowszych metod opartych na głębokim uczeniu.

Prawidłowe użycie akronimów jest jednym z elementów profesjonalnego stylu naukowego. Każdy akronim powinien być zdefiniowany przy pierwszym użyciu, a następnie stosowany konsekwentnie w całej pracy. Mieszanie pełnych nazw z akronimami bez zachowania spójności utrudnia odbiór tekstu.

25.3. Przykłady prawidłowego stylu naukowego

Przeprowadzone eksperymenty potwierdzają skuteczność zaproponowanej metody. Wyniki na zbiorze testowym wskazują na poprawę miary F1 o czternaście punktów procentowych w porównaniu z metodą bazową. Poprawa jest statystycznie istotna przy poziomie ufności dziewięćdziesiąt pięć procent.

Na podstawie przeprowadzonych badań można sformułować następujące wnioski. Po pierwsze, jakość danych treningowych ma większy wpływ na wyniki niż wybór architektury modelu. Po drugie, augmentacja danych jest szczególnie skuteczna w przypadku klas rzadkich. Po trzecie, regulacja modelu jest konieczna przy małych zbiorach treningowych.

W niniejszej pracy zaproponowano nowe podejście do problemu dezinformacji morfologicznej. Podejście to łączy analizę statystyczną z regułami morfologicznymi, osiągając lepsze wyniki niż każde z tych podejść zastosowane osobno. Metoda została sprawdzona na czterech niezależnych zbiorach testowych.

26. Przegląd narzędzi open source dla polskiego NLP

Ekosystem narzędzi open source dla języka polskiego rozwijał się stopniowo na przestrzeni ostatnich dwudziestu lat. Inicjatywy akademickie, finansowane ze środków publicznych, dostarczyły podstawowych zasobów i narzędzi niezbędnych do badań nad przetwarzaniem języka polskiego. Rosnące zainteresowanie polskim NLP ze strony przemysłu przyspieszyło ten rozwój w ostatniej dekadzie.

Kite, PoliMorf, Morfeusz2 i Poliqarp to przykłady narzędzi opracowanych w polskich ośrodkach akademickich i udostępnionych na otwartych licencjach. Każde z tych narzędzi skupia się na innym aspekcie analizy językowej. Ich integracja w spójne potoki przetwarzania wymaga nakładu inżynieryjnego, lecz daje dostęp do specjalistycznych zasobów nieosiągalnych w modelach ogólnych.

Społeczność polskich badaczy NLP, skupiona wokół konferencji PolEval i warsztatów TLT-Poland, aktywnie wymienia się wynikami badań i zasobami. Organizowane corocznie zadania ewaluacyjne PolEval pozwalają na obiektywne porównanie rozwiązań różnych zespołów. Wyniki tych ewaluacji stanowią punkt odniesienia dla oceny jakości nowych systemów.

26.1. Aktualne trendy i kierunki badań

Wielkie modele językowe, trenowane na setkach miliardów tokenów, stanowią nową klasę narzędzi NLP. Modele takie jak GPT czy Llama osiągają imponujące wyniki w zadaniach generowania tekstu, tłumaczenia i odpowiadania na pytania. Ich zastosowanie w przetwarzaniu polszczyzny jest ograniczone przez dysproporcję między ilością polskich i angielskich danych treningowych.

Fine-tuning wielkich modeli językowych na polskich danych jest aktywnym obszarem badań. Modele takie jak polskie wersje BERT czy Llama, dostosowane do języka polskiego, osiągają znacząco lepsze wyniki niż modele wielojęzyczne na zadaniach specyficznych dla polszczyzny. Koszt trenowania takich modeli jest jednak znaczący i wymaga dostępu do infrastruktury obliczeniowej.

Instrukcyjne fine-tuning modeli, znane jako instruction tuning lub RLHF, dostosowuje modele do wykonywania instrukcji w języku naturalnym. Modele po takim dostosowaniu mogą być używane jako asystenci zdolni do wykonywania różnorodnych zadań językowych na polecenie użytkownika. Jakość takich systemów dla języka polskiego nadal ustępuje rozwiązaniom dla języka angielskiego.

26.2. Wkład środowiska akademickiego

Polskie uczelnie i instytuty badawcze wnoszą istotny wkład w globalny postęp NLP. Prace polskich badaczy są regularnie prezentowane na czołowych konferencjach takich jak ACL, EMNLP czy COLING. Współpraca z partnerami zagranicznymi otwiera dostęp do zasobów i infrastruktury niedostępnych w kraju.

Granty badawcze finansowane ze środków europejskich i krajowych umożliwiają prowadzenie długoterminowych projektów badawczych. Program Horyzont Europa wspiera projekty interdyscyplinarne łączące lingwistykę obliczeniową z informatyką i innymi dziedzinami. Wyniki tych projektów są upubliczniane zgodnie z zasadami otwartej nauki.

Kształcenie specjalistów w dziedzinie NLP na polskich uczelniach intensywnie się rozwija. Programy studiów magisterskich i doktoranckich uwzględniają coraz więcej treści z zakresu uczenia maszynowego i przetwarzania języka naturalnego. Absolwenci tych programów zasilają zarówno środowisko akademickie, jak i przemysłowe zespoły badawcze.

27. Zakończenie i perspektywy

Dziedzina przetwarzania języka naturalnego stoi u progu kolejnego przełomu. Rosnące możliwości obliczeniowe, coraz większe zbiory danych i nowe architektury modeli otwierają perspektywy dotychczas nieosiągalne. Języki o dotychczas ograniczonej reprezentacji, w tym język polski, będą stopniowo zyskiwać na jakości dostępnych dla nich narzędzi.

Automatyczna analiza i korekta stylu naukowego jest jednym z wielu zastosowań, które będą korzystać z tych postępów. Narzędzia wspomagające autorów staną się coraz bardziej precyzyjne i kontekstowo świadome. Granica między automatyczną sugestią a ręczną korektą będzie się przesuwać w miarę poprawy jakości modeli.

Niniejsza praca stanowi wkład w budowanie ekosystemu narzędzi dla polskiego NLP. Opracowany system i zgromadzone doświadczenia mogą służyć jako punkt wyjścia dla kolejnych prac badawczych. Kontynuacja badań w tym kierunku jest uzasadniona zarówno z perspektywy naukowej, jak i praktycznych potrzeb środowiska akademickiego.